CNN 심화 (2)

Deep Session 6차시

CONTENTS.

01. Review

- LeNet
- VGG
- AlexNet

02. 기초 모델 아키텍처

- ResNet

03. 논문 리뷰

- GoogLeNet

LeNet

- 초기의 컨볼루션 신경망 중 하나로, 주로 손으로 쓴 숫자 인식에 사용되었던 모델

- 32 x 32 크기의 흑백 이미지에서 학습된 7 layer CNN (Input 층 제외)

- Input → Conv (C1) → Subsampling (S2) → Conv (C3) → Subsampling (S4) → Conv (C5) → FC6 → FC7 (Output)

1x32x32 — 6개의 5x5 필터 사용, 6x28x28 — stride=2, 2x2 평균 풀링, 6x14x14 — 16개의 5x5 필터 사용, 16x10x10 — stride=2, 2x2 평균 풀링, 16x5x5 — 120x1x1, 120개의 stride=1, 5x5 필터 사용 — tanh 활성화 함수, 84 — RBF 활성화 함수, 10

- 깊은 학습 네트워크로 발전하는 데 큰 발판

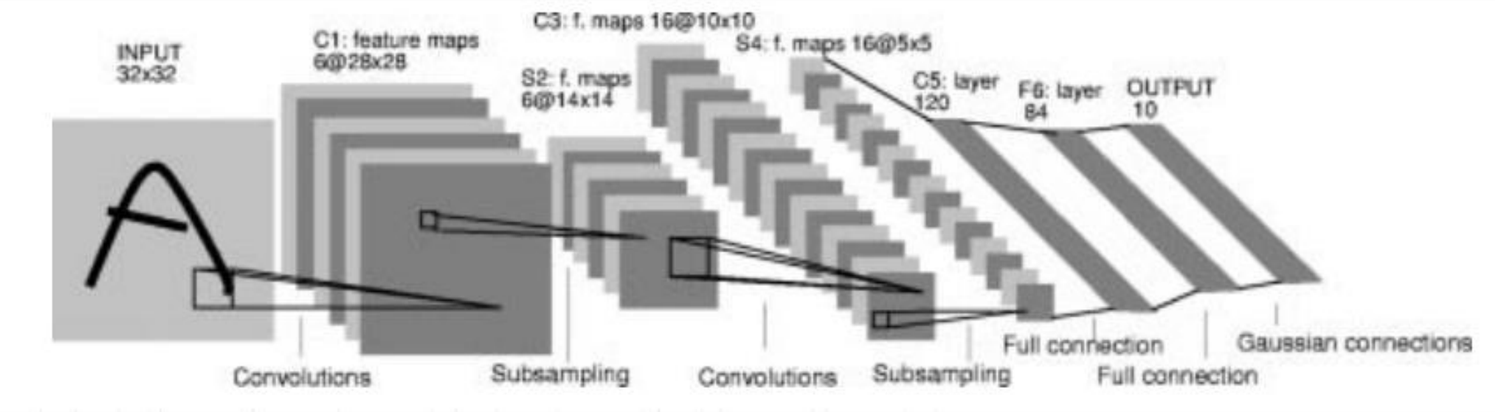

VGG

- 매우 깊고 단순한 네트워크로 더 높은 성능
- 3x3 필터 사용 + zero-padding 사용하여 더 깊게, 더 좋은 표현력
- 매우 많은 수의 파라미터, 계산 비용과 메모리 사용량이 큰 단점

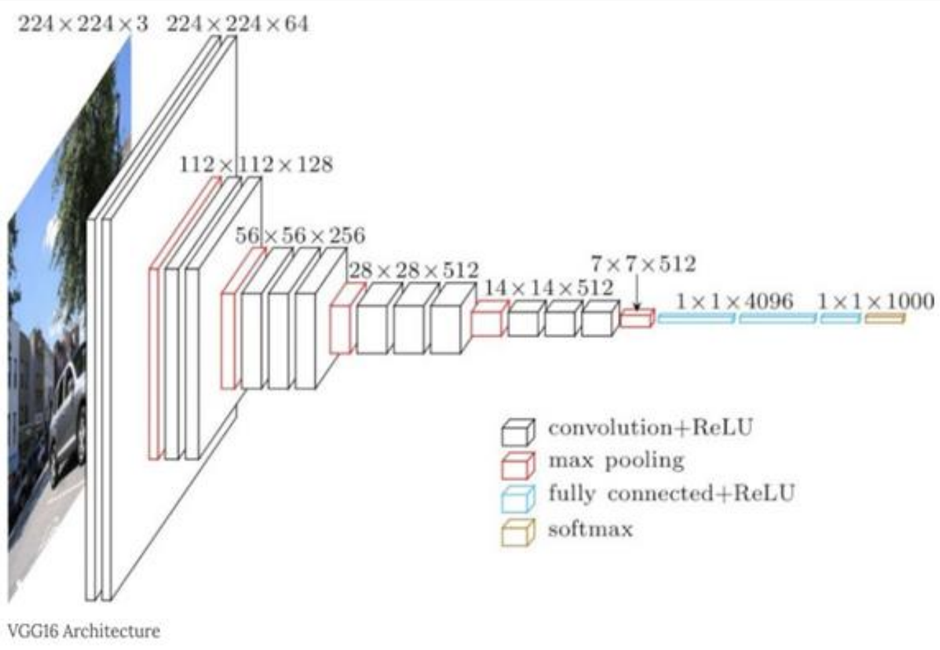

VGG16 Architecture

- Input → C1 → C2 → MaxPool2
  64개의 stride=1, padding=1, 3x3 필터 / stride=2, 2x2 최대 풀링

→ C3 → C4 → MaxPool4
128개의 stride=1, padding=1, 3x3 필터 / stride=2, 2x2 최대 풀링

→ C5 → C6 → C7 → MaxPool7
256개의 stride=1, padding=1, 3x3 필터 / stride=2, 2x2 최대 풀링

→ C8 → C9 → C10 → MaxPool10
512개의 stride=1, padding=1, 3x3 필터 / stride=2, 2x2 최대 풀링

→ C11 → C12 → C13 → MaxPool13
512개의 stride=1, padding=1, 3x3 필터 / stride=2, 2x2 최대 풀링

→ FC14 → FC15 → FC16(Output)
ReLU 활성화 함수 / Softmax 함수

AlexNet

- 2개의 GPU로 병렬연산 수행을 위한 병렬적인 구조 + 대규모의 깊은 8층 구조의 CNN 모델
- Data Augmentation + Overlapping Max Pool + LRN → 강력한 피처 추출과 일반화 능력 향상
- Input → C1 → MaxPool1 → C2 → MaxPool2→ C3 → C4 → C5 → MaxPool5 → FC6 → FC7 → FC8 (Output)
  → C1 → MaxPool1 → C2 → MaxPool2→ C3 → C4 → C5 → MaxPool5 → FC6 → FC7 →

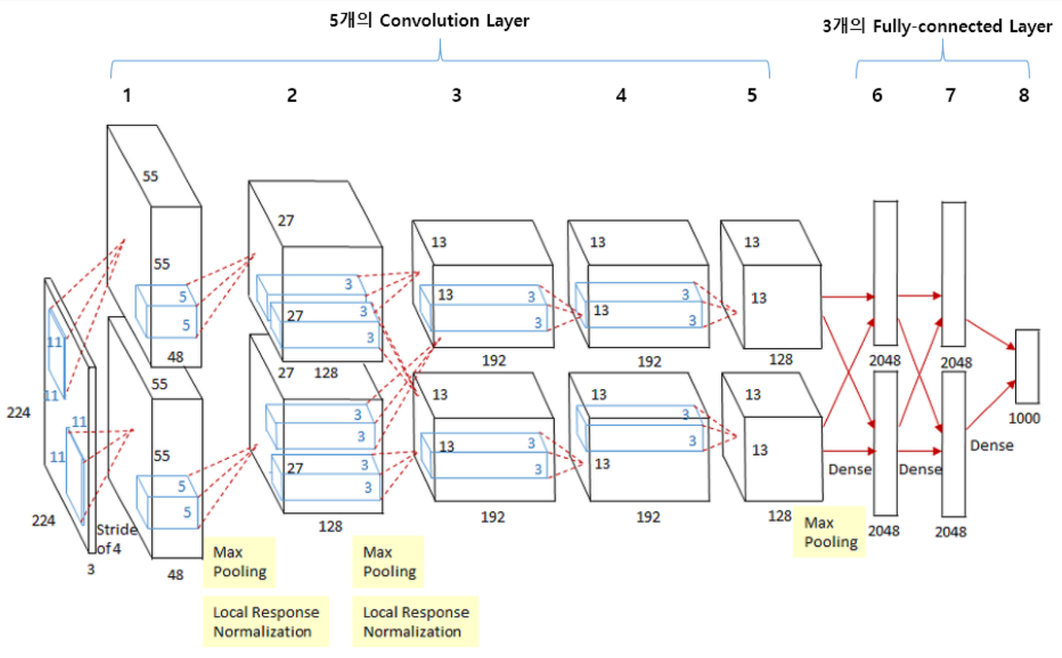

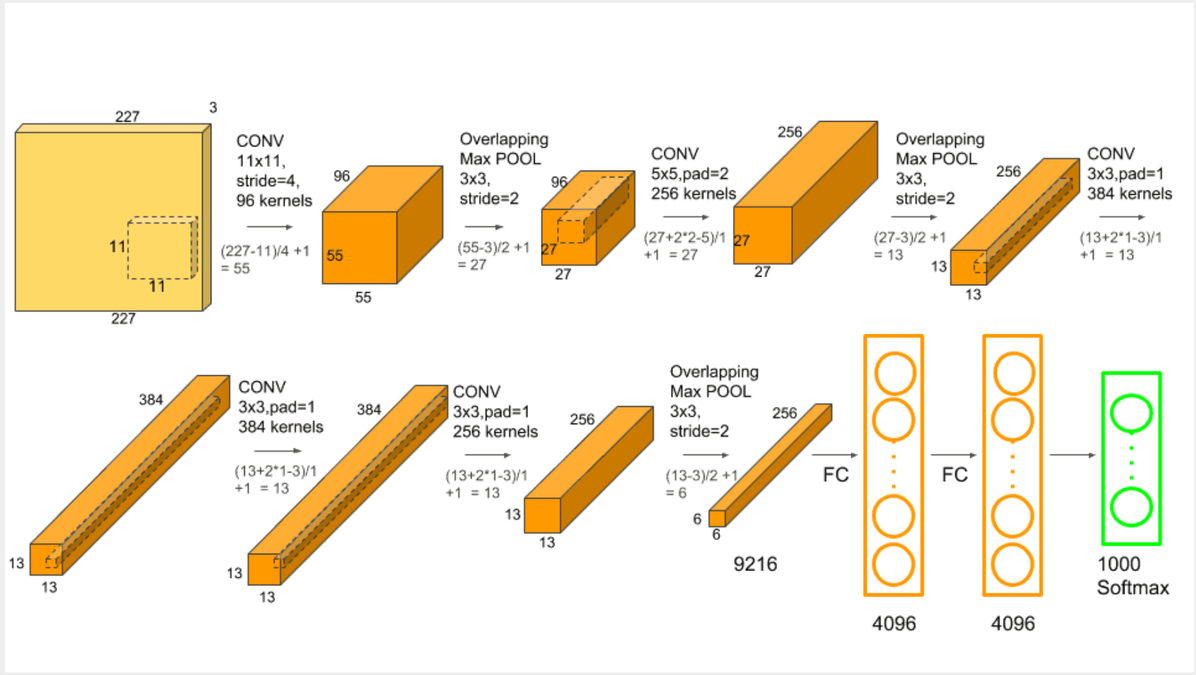

ResNet

Intro

- 깊은 신경망을 학습할 때 발생할 수 있는 문제 완화
- Residual Network의 줄임말
- VGG 보다 8배 깊은 152개의 layer 사용, 더 적은 복잡도
- 3.57%의 error
- ILSVRC 2015 등 다양한 분야 대회에서 1위 차지

ResNet

Intro

깊이가 깊어질수록 네트워크의 성능은 향상될까?

- 일정 범위 이상의 layer가 증가할수록 오히려 더 높은 error 발생

→ vanishing/exploding gradients, overfitting 등의 문제

→ 연산이 진행되면서 원래 정보를 잃게 됨

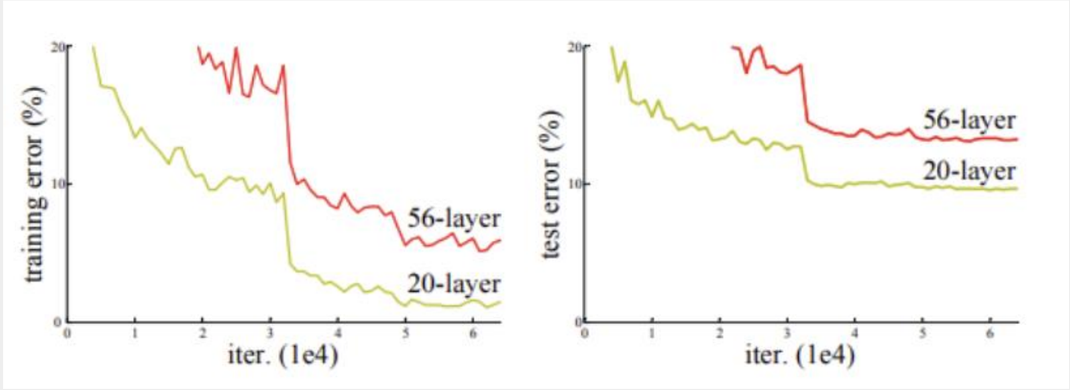

➔ layer를 깊게 쌓되, 학습하는 양을 줄이자!

➔ layer를 거친 값(output)에 x(input)를 더해줘 기존 정보를 살리자!

ResNet

구조

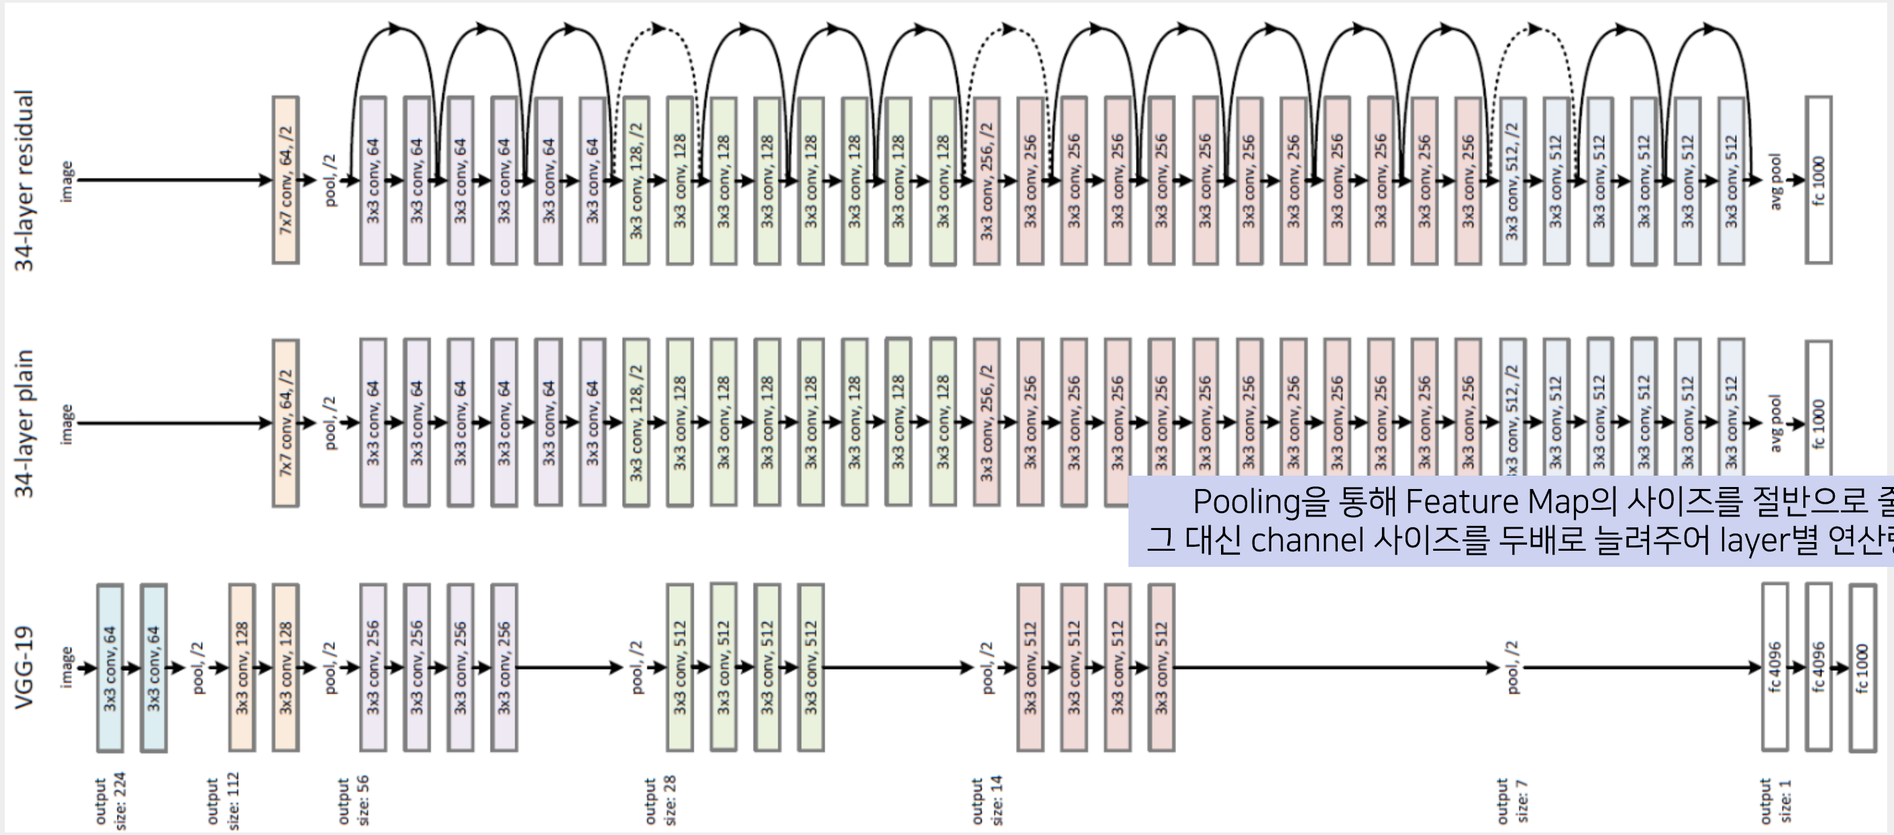

Pooling을 통해 Feature Map의 사이즈를 절반으로 줄어듦
그 대신 channel 사이즈를 두배로 늘려주어 layer별 연산량을 유지

ResNet

주요 특징

1. residual learning
2. shortcut(skip) connection

→ vanishing gradients 문제 완화

→ 깊은 네트워크에서도 안정적인 학습 가능

→ 원래의 입력 정보를 보존하여 전체 네트워크의 학습 능력을 향상

ResNet

1. residual learning (잔차 학습)

- 기존의 경우

- input을 x로 받아 2개의 weight layer를 거친 결과값
- 학습을 통해 최적의 H(x)를 구해내는 것이 목표 → 어려움

ex. 기존 VGG에서 3x3 conv를 통해 얻는 값

- 논문의 경우

- 기존 정보(x)에 새로 추가된 레이어를 학습한 값(F(x))을 더한 값
- 최적의 F(x)를 구해내는 것이 목표 → 상대적으로 쉬움

기존 정보(x)에

새로운 레이어를 추가적으로 누적해서 다시 학습시킴

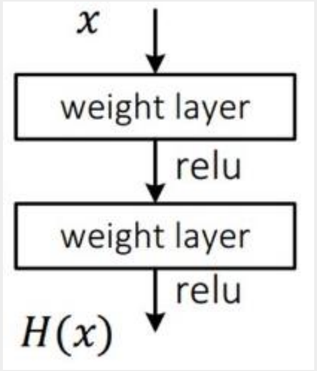

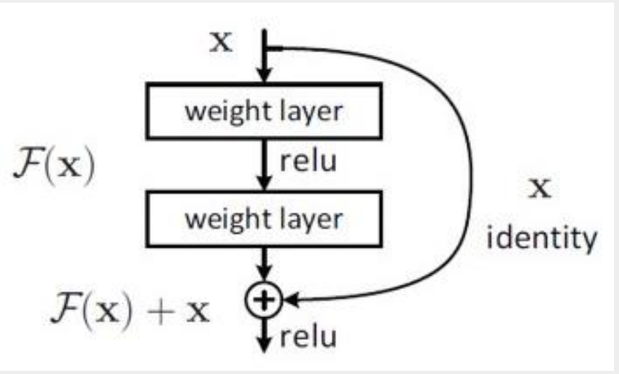

F(x) + x := H(x)

F(x) = H(x) - x

기존 정보(x)는 학습하지 않고,

새로 추가된 레이어에 대한 부분만 학습시킴

ResNet

1. residual learning (잔차 학습)

- F(x) = H(x) – x (예측값 – 실제값 = 잔차)
- 잔차 학습 = 입력 x에서 수정만을 추가로 학습 → ‘보정’ 역할
- H(x)를 맞추는 것보다 F(x)가 거의 0이 되는 방향으로 맞추는 것이 훨씬 쉬움
- 차이에 대한 학습만 하기 때문에 훨씬 연산량 감소

ResNet

2. shortcut(skip) connection (단축 연결)

- ‘Gradient가 잘 도달할 수 있게 지름길을 뚫어주자’
- 입력 x를 여러 개의 층을 거치지 않고 바로 출력층에 더하는 방식
- 추가적인 매개변수 X → 연산량과 복잡도 낮음

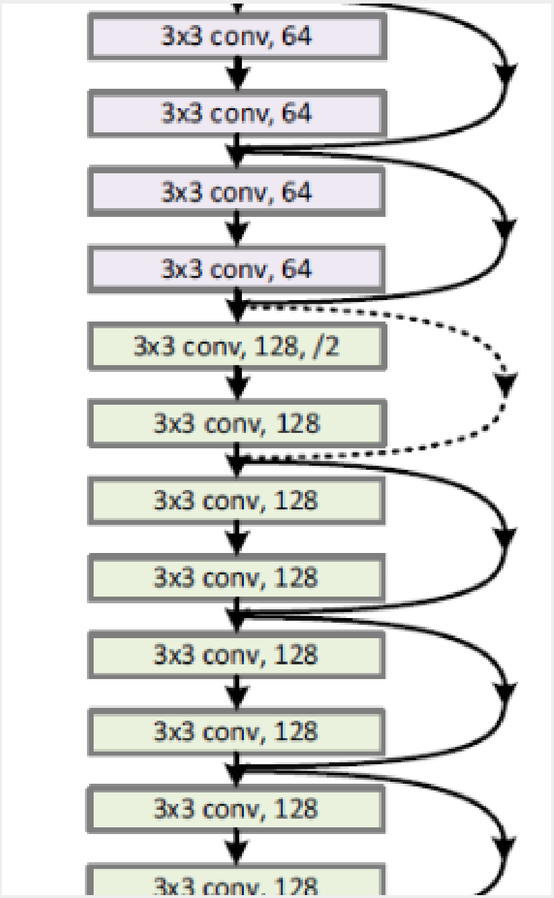

ResNet

2. shortcut(skip) connection (단축 연결)

구현 방식

- Identity Shortcut (일반적인 구조) - 실선

  : 입력과 출력의 차원이 같을 때 사용

  입력을 변경 없이 직접 출력에 더함

- Projection Shortcut - 점선

  : 입력과 출력의 차원이 같지 않을 때 사용

  입력을 선형 변환(ex. 1x1 conv)을 통해 출력의 차원과 일치시킨 후 출력에 더함

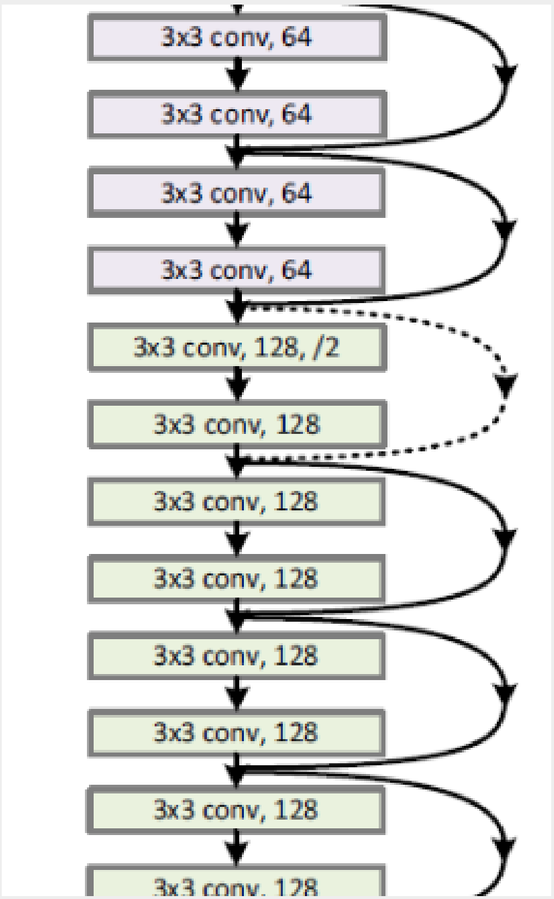

ResNet

Outro

- layer가 50개 이상이 될 때 1x1 conv를 통해 연산량을 줄여줌 (깊을수록 1x1 conv 효과 명확)

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2 [3×3, 64; 3×3, 64] ×2	[3×3, 64; 3×3, 64] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3
conv3_x	28×28	[3×3, 128; 3×3, 128] ×2	[3×3, 128; 3×3, 128] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×8
conv4_x	14×14	[3×3, 256; 3×3, 256] ×2	[3×3, 256; 3×3, 256] ×6	[1×1, 256; 3×3, 256; 1×1, 1024] ×6	[1×1, 256; 3×3, 256; 1×1, 1024] ×23	[1×1, 256; 3×3, 256; 1×1, 1024] ×36
conv5_x	7×7	[3×3, 512; 3×3, 512] ×2	[3×3, 512; 3×3, 512] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

Bottleneck Architecture

1x1 conv: 차원 축소 → 중요한 피처 보존

3x3 conv: 줄어든 채널을 3x3 conv 연산 → Receptive Field 확장

1x1 conv: 원래대로 차원 맞춰줌 → 중요한 피처 보존

➔ 모델을 깊게 쌓으면서 동시에 연산량을 줄이는 것이 핵심 전략

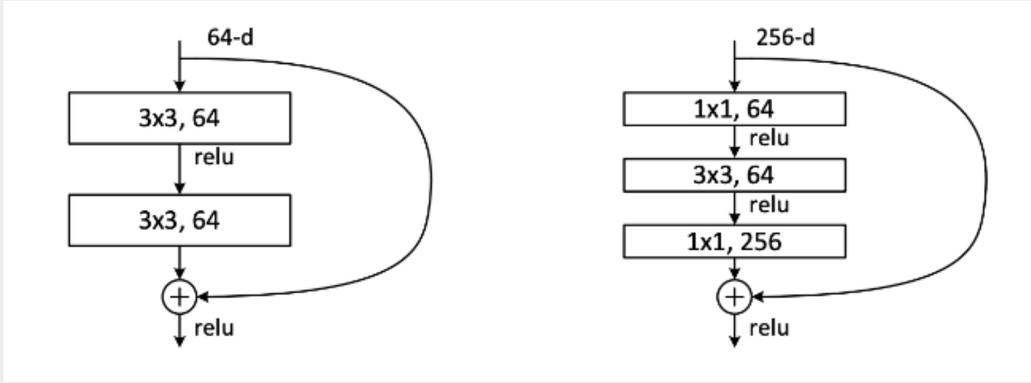

left. 일반적인 구조의 ResNet: (3 * 3 * 64) * 2 = 1,152

right. Bottle Neck ResNet: (1 * 1 * 64) + (3 * 3 * 64) + (1 * 1 * 256) = 896

ResNet

Outro

- 18 layer보다 더 깊은 34 layer에서 더 낮은 에러율
- 18 layer에서는 plain과 ResNet의 에러율 비슷하나, ResNet의 학습 파라미터 수가 더 적어 학습 속도가 더 빠름

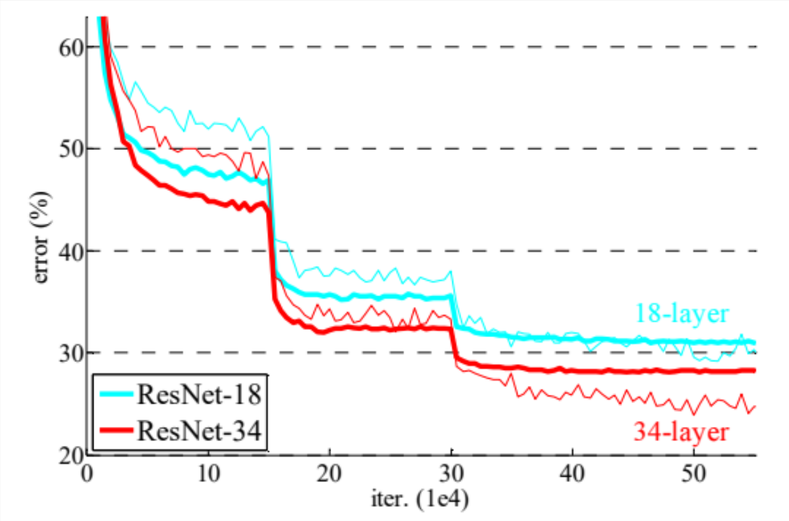

	plain	ResNet
18 layers	27.94	27.88
34 layers	28.54	**25.03**

Table 2. Top-1 error (%, 10-crop testing) on ImageNet validation. Here the ResNets have no extra parameter compared to their plain counterparts. Fig. 4 shows the training procedures.

ResNet

정리

- 핵심: Residual Learning & Shortcut Connection

→ 기존 Neural Network보다 깊이가 깊어져도 학습 및 최적화가 쉬움

→ 기존 Neural Network보다 깊이가 깊어져도 파라미터 수는 더 적음

→ ResNet의 깊이가 깊어져도 성능 꾸준히 상승

➔ 컴퓨터 비전 분야에서 매우 중요한 발전을 이루었으며, 다양한 분야에서 널리 사용

➔ 딥 러닝 모델의 설계에 많은 영감, 후속 모델에 영향

GoogLeNet

과제

ResNet 논문 리뷰

https://arxiv.org/pdf/1512.03385.pdf

THANK YOU

Deep Session 6차시